

MINERÍA DE DATOS APLICADO A LOS NEGOCIOS

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543



INTRODUCCIÓN MINERÍA DE DATOS









Established in the Lanes
Since 1914

DOYLES ANTIQUE JEWELLERS




*Fine Secondhand Diamond and Gemset -
Jewellery FOR SALE*
WE BUY Antique Diamond Jewellery FOR CASH

**Fine Antique
JEWELLERY**
And DIAMOND

Buying Beautiful Secondhand
**DIAMOND
JEWELLERY**
Can Save You
50% ON MODERN HIGH
STREET JEWELLERS

*Classic
WATCHES
TED FOR CASH
Cartier Rolex Phillips
at good makes*






MINERÍA DE DATOS VS ESTADÍSTICA TRADICIONAL



Aspecto	Estadística tradicional	Minería de datos
Enfoque	Explicar fenómenos, probar hipótesis, validar teorías	Descubrir patrones ocultos y predecir comportamientos
Punto de partida	Parte de hipótesis formuladas previamente	Parte de los datos en bruto (exploración automática)
Tipo de datos	Muestras pequeñas y bien estructuradas	Grandes volúmenes, muchas veces ruidosos/no estructurados
Métodos	Regresión, ANOVA, pruebas de hipótesis, intervalos	Árboles de decisión, clustering, redes neuronales, reglas de asociación
Orientación	Interpretación, causalidad, significancia estadística	Predicción, exactitud y utilidad práctica
Herramientas	R, SPSS, SAS, STATA	Python, R, SQL, Spark, Weka, TensorFlow, RapidMiner





VISA & MASTERCARD

Problema: pérdidas millonarias por transacciones fraudulentas.

Uso de minería de datos: modelos de clasificación que detectan patrones anómalos en segundos.

Resultado: bloqueo casi en tiempo real de operaciones sospechosas.

Impacto: reducción drástica de fraudes y aumento de confianza de clientes.



MARRIOT

Problema: dificultad para personalizar la experiencia del cliente en miles de hoteles alrededor del mundo.

Uso de minería de datos: clusterización de reservas y consumos (duración de estadía, gasto en restaurantes/spa, tipo de habitación, motivo del viaje).

Resultado: identificación de clústeres como viajeros de negocios, familias vacacionales, parejas de lujo, y viajeros frecuentes de bajo costo.

Impacto: estrategias de marketing y programas de lealtad más efectivos → aumento de ingresos por cliente y mayor satisfacción.



COCA COLA

Problema: necesitaban justificar el gasto millonario en publicidad televisiva.

Uso de estadística: modelos de **regresión múltiple** para medir la relación entre inversión en anuncios, promociones en punto de venta y variación en ventas por región.


Resultado: descubrieron que la **publicidad televisiva tenía un efecto significativo en el corto plazo**, pero las **promociones en tienda impactaban más en el largo plazo**.

Impacto: optimización del presupuesto de marketing → mejor retorno sobre inversión (ROI).





CRISP-DM



Business Understanding

“The main objective is to ask the right questions, while the choice of the right techniques for a specific case is secondary”

Data Understanding

“This phase aims to familiarize the data analyst with the data and to ensure that the data is suitable for the intended analysis”

Data Preparation

“Data preparation is often a lengthy undertaking for data professionals or business users, but it is essential as a prerequisite to put data in context in order to turn it into insights and eliminate bias resulting from poor data quality”

Modeling

“This phase selects and fine-tunes appropriate techniques for the best model. It also includes comparing different models and selecting the best one and testing models using unseen data. Model accuracy is important, but understanding feature impact is also necessary for decision-making”

Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
Determine Business Objectives <i>Background</i> <i>Business Objectives</i> <i>Business Success</i> <i>Criteria</i>	Collect Initial Data <i>Initial Data Collection Report</i>	<i>Data Set</i> <i>Data Set Description</i>	Select Modeling Technique <i>Modeling Technique</i> <i>Modeling Assumptions</i>	Evaluate Results <i>Assessment of Data Mining Results w.r.t. Business Success Criteria</i> <i>Approved Models</i>	Plan Deployment <i>Deployment Plan</i>
Assess Situation <i>Inventory of Resources</i> <i>Requirements, Assumptions, and Constraints</i> <i>Risks and Contingencies</i> <i>Terminology</i> <i>Costs and Benefits</i>	Describe Data <i>Data Description Report</i>	Select Data <i>Rationale for Inclusion/Exclusion</i>	Generate Test Design <i>Test Design</i>	Review Process <i>Review of Process</i>	Plan Monitoring and Maintenance <i>Monitoring and Maintenance Plan</i>
Determine Data Mining Goals <i>Data Mining Goals</i> <i>Data Mining Success Criteria</i>	Explore Data <i>Data Exploration Report</i>	Clean Data <i>Data Cleaning Report</i>	Build Model <i>Parameter Settings</i> <i>Models</i> <i>Model Description</i>	Determine Next Steps <i>List of Possible Actions</i> <i>Decision</i>	Produce Final Report <i>Final Report</i> <i>Final Presentation</i>
Produce Project Plan <i>Project Plan</i> <i>Initial Assessment of Tools and Techniques</i>	Verify Data Quality <i>Data Quality Report</i>	Construct Data <i>Derived Attributes</i> <i>Generated Records</i>	Assess Model <i>Model Assessment</i> <i>Revised Parameter Settings</i>		Review Project <i>Experience</i> <i>Documentation</i>
		Integrate Data <i>Merged Data</i>			
		Format Data <i>Reformatted Data</i>			

CASO: DISCRIMINACIÓN DE GÉNERO



Departamento	Hombres solicitantes	% Admitidos H	Mujeres solicitantes	% Admitidas M
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	373	6%	341	7%
Total	2,691	45%	1,835	30%

MINERÍA DE DATOS APLICADO A LOS NEGOCIOS

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543