



APRENDIZAJE NO SUPERVISADO

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543





1.1 ¿Qué es el Aprendizaje No Supervisado?

Analogía. En el aprendizaje supervisado, se proporciona al algoritmo ejemplos con etiquetas (p. ej., “manzana”, “naranja”). En el aprendizaje no supervisado, solo se observan los datos y el objetivo es descubrir su estructura subyacente.

Definición (técnica). El aprendizaje no supervisado es una rama del aprendizaje automático en la cual el conjunto de datos

$$X = \{x^{(1)}, x^{(2)}, \dots, x^{(m)}\} \subset \mathbb{R}^n$$

no tiene etiquetas asociadas. El objetivo es encontrar patrones, estructuras o relaciones ocultas en los datos.

Formalmente,

- No existe una función objetivo con “respuesta correcta” $y^{(i)}$.
El algoritmo busca una función f tal que

$$f : \mathbb{R}^n \rightarrow \mathcal{Z}$$

que revele alguna estructura en los datos, donde $\mathcal{Z}$ puede representar grupos, componentes, representaciones latentes, entre otros.

Ejemplos de tareas. Clustering (agrupamiento), reducción de dimensionalidad, detección de anomalías, aprendizaje de representaciones, estimación de densidad, entre otras.




Figura 1.1: Ejemplo de agrupamiento en $\mathbb{R}^2$. El algoritmo busca particionar los datos en grupos (*clusters*) según su similitud, sin conocer etiquetas.

5.3 Estructura de un Proyecto de ML No Supervisado (Nivel Senior)

Un proyecto real de aprendizaje no supervisado requiere una metodología rigurosa que cubra desde la definición del problema hasta la entrega de valor de negocio. La Figura 5.1 presenta el flujo de trabajo recomendado.



Figura 5.1: Flujo de trabajo para un proyecto de ML no supervisado.

5.4 Estructura de Proyecto (Vista de Software)

Una buena organización del código y los datos es clave para proyectos reproducibles y escalables.



2 Manejo de valores faltantes (Imputación)

Numéricos:

- Media / mediana

2.1	3.5	4.2
1.8	—	2.9
3.0	2.7	—
2.5	3.1	3.8

Catégoricos:

- Moda

Color	Valor
Rojo	
Azul	
Azul	
—	
Rojo	→ Azul
Azul	

Más avanzado:

- KNN Imputer





👉 En no supervisado, imputar mal puede crear “clusters falsos”.

3 Tratamiento de outliers

Muy importante porque afectan distancias.

- Eliminación (IQR, Z-score)
- Transformación (log)
- Métodos robustos



👉 K-Means y PCA son especialmente sensibles a esto.

4 Codificación de variables catégoricas

- One-Hot Encoding (más común)

Color	Rojo	Azul	Verde
Rojo	1	0	0
Azul	0	1	0
Verde	0	0	1

- Ordinal Encoding (si tiene orden)

Tamaño	Código
Pequeño	1
Mediano	2
Grande	3

👉 Necesario porque los algoritmos trabajan con números.

5 Escalado de variables (CRÍTICO)


Uno de los pasos más importantes.

- Standardization (Z-score): $z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$

- Min-Max Scaling:

$$\tilde{x}_{ij} = \frac{x_{ij} - \min_j}{\max_j - \min_j} \in [0, 1]$$

- Robust Scaling (si hay outliers): $x_{ij}^{rob} = \frac{x_{ij} - \text{mediana}_j}{IQR_j}$



👉 Sin esto:

- K-Means falla
- PCA se distorsiona (varianza domina por escala)

6 Transformaciones de distribución


Cuando los datos están sesgados:

- Log transform: $x' = \log(x + c)$, $c > 0$


- Box-Cox: $x'(\lambda) = \begin{cases} \frac{x^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \log(x), & \lambda = 0 \end{cases}$

- Yeo-Johnson: $x'(\lambda) = \begin{cases} \frac{(x+1)^\lambda - 1}{\lambda}, & x \geq 0, \lambda \neq 0, \\ \log(x+1), & x \geq 0, \lambda = 0, \\ -\frac{(-x+1)^{2-\lambda} - 1}{2-\lambda}, & x < 0, \lambda \neq 2, \\ -\log(-x+1), & x < 0, \lambda = 2 \end{cases}$


Distribución sesgada



Después de log transform



Más simétrica (ideal)



👉 Ayuda a que:

- distancias sean más representativas
- PCA capture mejor la estructura

1 Prueba T (Comparación de medias)


Compara la media de dos grupos.
Supuesto: datos ~ Normal, varianzas iguales (o usar corrección Welch).

— Grupo 1
--- Grupo 2

- Dos muestras independientes

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$


$$gl = n_1 + n_2 - 2$$



- Dos muestras relacionadas (pareadas)

$$t = \frac{\bar{D}}{s_D / \sqrt{n}}$$

$$gl = n - 1$$



👉 Usos: comparar antes/después, grupo tratamiento vs. control (media).

2 ANOVA (Análisis de Varianza)

Compara la media de 3 o más grupos independientes.

H_0 : todas las medias son iguales.

- Estadístico F

$$F = \frac{MS_{entre}}{MS_{dentro}} = \frac{SS_{entre}/(k-1)}{SS_{dentro}/(N-k)}$$


donde:

$$SS_{entre} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2$$

$$SS_{dentro} = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

$$gl = (k-1, N-k)$$

- Visualización



👉 Si se rechaza H_0 , usar pruebas post-hoc (Tukey, Bonferroni, etc.).

3 A/B Testing (Prueba de hipótesis para conversión)


Compara dos versiones (A vs B) en una métrica (conversión, clics, ingresos, etc.).

Usualmente para proporciones.

- Prueba Z para dos proporciones

$$Z = \frac{\hat{p}_A - \hat{p}_B}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_A} + \frac{1}{n_B}\right)}}$$

$$\text{donde } \hat{p} = \frac{x_A + x_B}{n_A + n_B}$$



- H_0 : $p_A = p_B$ (no hay diferencia)

- H_1 : $p_A \neq p_B$ ($>$, $<$ según la métrica)

👉 Usos: evaluar cambios en producto, marketing, diseño web, etc.

4 MANOVA (Análisis Multivariado de Varianza)

Extensión del ANOVA cuando hay múltiples variables dependientes.

Compara vectores de medias entre grupos.

H_0 : los vectores de medias son iguales.


- Estadísticos comunes

- Wilks' Lambda: $\Lambda = \frac{|W|}{|T|}$
- Pillai's Trace: $V = \text{tr}(E(E+H)^{-1})$
- Hotelling's Trace: $T^2 = \text{tr}(HE^{-1})$
- Roy's Largest Root: $\theta = \lambda_{\max}(HE^{-1})$

donde:

H = matriz de suma de cuadrados y productos entre grupos

E = matriz de suma de cuadrados y productos dentro de grupos



👉 Usos: comparar grupos en varias métricas simultáneamente (ej. rendimiento en matemáticas y lenguaje).

5 Chi Cuadrado (χ^2) (Prueba de Independencia / Bondad de Ajuste)

a) Independencia en tablas de contingencia

H_0 : las variables son independientes.

- Estadístico


$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

donde $E_{ij} = \frac{(\text{total fila}_i)(\text{total columna}_j)}{N}$

$$gl = (r-1)(c-1)$$

- Visualización (ejemplo 2x3)

	Columna			Total
	1	2	3	
Fila 1	10	15	20	45
Fila 2	20	25	10	55
Total	30	40	30	100



👉 Usos: analizar asociación entre variables categóricas, verificar si una distribución sigue lo esperado.

b) Bondad de ajuste

H_0 : la distribución observada sigue la esperada.


- Estadístico

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

$$gl = k - 1 - p$$

(p = parámetros estimados)

- Visualización (ejemplo)



T-STUDENT


Es una prueba estadística que compara las **medias de dos grupos**

Permite saber si la diferencia observada es **real o producto del azar**


Trabaja con muestras **pequeñas**



Es un test **paramétrico**

Distribuciones paramétricas (t-test)



Distribuciones no paramétricas (Mann-Whitney)





$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

Donde:

- $\bar{X}_1, \bar{X}_2$: medias de los grupos
- s_p : desviación combinada
- n_1, n_2 : tamaños de muestra

```
from scipy.stats import ttest_ind

ventas_A = [100, 110, 95, 105, 98, 102, 97]
ventas_B = [120, 125, 130, 128, 122, 118, 127]

t, p = ttest_ind(ventas_A, ventas_B)

print(f"t = {t:.2f}, p = {p:.5f}")


if p < 0.05:
    print("Diferencia significativa: la Estrategia B mejora las ventas.")
else:
    print(" No hay diferencia significativa entre las estrategias.")
```

```
t = -6.12, p = 0.0001
Diferencia significativa: la Estrategia B mejora las ventas.
```

Resultado del test	Qué significa estadísticamente	Interpretación práctica
$p < 0.05 \rightarrow$ Rechazamos H_0	Hay evidencia de diferencia.	Las ventas de A y B son distintas.
$p \geq 0.05 \rightarrow$ No rechazamos H_0	No hay evidencia de diferencia.	Las ventas son similares, cualquier diferencia podría ser por azar.

Resultado del test	Qué significa estadísticamente	Interpretación práctica
$p < 0.05 \rightarrow$ Rechazamos H_0	Hay evidencia de diferencia.	Las ventas de A y B son distintas.
$p \geq 0.05 \rightarrow$ No rechazamos H_0	No hay evidencia de diferencia.	Las ventas son similares, cualquier diferencia podría ser por azar.
“Rechazar H_0” no significa que H_1 sea 100% verdadera, sino que hay evidencia suficiente para creer que existe una diferencia. “No rechazar H_0” no significa que las medias sean exactamente iguales, sino que no hay suficiente evidencia para afirmar que difieren.		

A/B Testing




ANOVA

El ANOVA permite comparar **tres o más medias (usando varianza)** para determinar si al menos una de ellas es significativamente diferente

Permite saber si la diferencia observada es **real o producto del azar**

El t-Student compara **medias**, el ANOVA compara **varianzas entre medias**

Es un test **paramétrico**



```
from scipy.stats import f_oneway
```

```
A = [100, 105, 98, 110, 102]
```

```
B = [115, 118, 120, 117, 119]
```

```
C = [95, 92, 100, 97, 94]
```

```
F, p = f_oneway(A, B, C)
```

```
print(f"F = {F:.2f}, p = {p:.5f}")
```

```
if p < 0.05:
```

```
    print("Hay diferencias significativas entre las estrategias.")
```

```
else:
```

```
    print("No hay diferencias significativas entre las estrategias.")
```

F = 49.36, p = 0.00001

Hay diferencias significativas entre las estrategias.

MANOVA

MANOVA es una extensión del ANOVA, pero en lugar de comparar **una sola variable dependiente**, compara **varias variables dependientes al mismo tiempo**.

Si el MANOVA es significativo, se realizan ANOVA's univariadas o pruebas de Tukey para ver en qué **variable están las diferencias**

Es un test **paramétrico**

Sensible a violaciones de normalidad o varianzas desiguales;
requiere muestras **moderadas o grandes**

```
import pandas as pd
from statsmodels.multivariate.manova import MANOVA
```




```
data = {
    "Rendimiento": [80, 82, 78, 75, 77, 79, 88, 90, 92],
    "Estres":      [60, 58, 65, 70, 72, 68, 55, 52, 50],
    "Grupo":       ["A", "A", "A", "B", "B", "B", "C", "C", "C"]
}
```

```
df = pd.DataFrame(data)
```

```
manova = MANOVA.from_formula("Rendimiento + Estres ~ Grupo", data=df)
print(manova.mv_test())
```

Multivariate linear model

	Value	Num DF	Den DF	F Value	Pr > F
Grupo	Wilks' lambda	0.08	4.0	10.0	5.85 0.010



CHI-SQUARED

¿Dos variables categóricas están relacionadas o son independientes?

1. Datos observados

Se encuestó a 200 personas sobre su género y su deporte favorito. La tabla muestra las frecuencias observadas (O).

Género Deporte	Fútbol	Básquetbol	Tenis	Total
Masculino	70	40	20	130
Femenino	30	25	15	70
Total	100	65	35	200

3. Frecuencias esperadas (E)

Bajo H_0 , la frecuencia esperada para cada celda es:

$$E_{ij} = \frac{(\text{Total fila}_i)(\text{Total columna}_j)}{\text{Total general}}$$

Género Deporte	Fútbol	Básquetbol	Tenis	Total
Masculino	65.00	42.25	22.75	130
Femenino	35.00	22.75	12.25	70
Total	100	65	35	200

(redondeado a 2 decimales)

5. Distribución y decisión

Parámetros:


- Nivel de significancia: $\alpha = 0.05$

- Grados de libertad:

$$gl = (r - 1)(c - 1) = (2 - 1)(3 - 1) = 2$$

- Valor crítico:

$$\chi^2_{0.05,2} = 5.991$$



Como $\chi^2_{calc} = 2.286 < \chi^2_{crit} = 5.991$
No se rechaza H_0 .

➡ **Conclusión:** No hay evidencia suficiente para afirmar que existe asociación entre el género y el tipo de deporte favorito.

2. Hipótesis

H_0 : El género y el tipo de deporte favorito son independientes.
(No existe asociación entre las variables)

H_1 : El género y el tipo de **deporte** favorito no son independientes.
(Existe asociación entre las variables)

4. Cálculo del estadístico χ^2

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$


Tabla de contribuciones por celda:

Género Deporte	Fútbol	Básquetbol	Tenis	Total
Masculino	0.385	0.120	0.332	0.837
Femenino	0.714	0.219	0.516	1.448
Total	1.099	0.339	0.848	2.286

$$\chi^2_{calc} = 2.286$$

6. p-valor

- $p\text{-valor} = P(\chi^2 \geq 2.286 \mid gl = 2) = 0.319$



Como $p\text{-valor} = 0.319 > \alpha = 0.05$
No se rechaza H_0 .

➡ **Conclusión (por p-valor):** No hay evidencia suficiente para afirmar que existe asociación entre el género y el tipo de deporte favorito.

APRENDIZAJE NO SUPERVISADO

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543