

# ANÁLISIS DE CORRESPONDENCIA SINPLE & MULTIPLE

Rachit Vargas (MBA | Engineer)

[rachit.vargas@ulead.ac.cr](mailto:rachit.vargas@ulead.ac.cr)

(+506) 8474-3543

# 1. INTRODUCCIÓN

## El problema de analizar asociaciones en datos categóricos

### 1.1 Tipos de datos y tabla de contingencia

Muchos estudios recogen información cualitativa en forma de tablas de contingencia de  $I$  individuos (filas) y  $J$  categorías (columnas).

Ejemplo de tabla de contingencia

|                    |               | Categorías (columnas) |          |          |          |            |
|--------------------|---------------|-----------------------|----------|----------|----------|------------|
|                    |               | 1                     | 2        | ...      | $J$      | Total fila |
| Individuos (filas) | 1             | $n_{11}$              | $n_{12}$ | ...      | $n_{1J}$ | $r_1$      |
|                    | 2             | $n_{21}$              | $n_{22}$ | ...      | $n_{2J}$ | $r_2$      |
|                    | $\vdots$      | $\vdots$              | $\vdots$ | $\ddots$ | $\vdots$ | $\vdots$   |
|                    | $I$           | $n_{I1}$              | $n_{I2}$ | ...      | $n_{IJ}$ | $r_I$      |
|                    | Total columna | $c_1$                 | $c_2$    | ...      | $c_J$    | $n$        |

$n_{ij}$ : frecuencia del individuo  $i$  en la categoría  $j$ .

### 1.2 ¿Qué queremos entender?

Nos interesa estudiar si existen asociaciones entre las categorías y los individuos. Por ejemplo:

- ¿Qué categorías tienden a aparecer juntas en los mismos individuos?
- ¿Hay grupos de individuos con perfiles de categorías similares?
- ¿Qué categorías caracterizan a cada grupo?

En otras palabras: queremos comprender la estructura de los datos categóricos más allá de los conteos.

### 1.3 El problema central

Cuando  $I$  y  $J$  son grandes, la tabla vive en un espacio de dimensión  $IJ$  (o  $(I - 1)(J - 1)$  tras restricciones), lo que genera varias dificultades:

- Es imposible visualizar e interpretar las asociaciones directamente en ese espacio.
- Hay mucha información y redundancia.
- No es claro cómo identificar patrones, grupos u oposiciones entre filas y columnas.


#### En síntesis:

El problema es cómo representar e interpretar las asociaciones entre filas e columnas de una tabla de contingencia de forma clara, intuitiva y en un espacio manejable.

### 1.4 Ilustración del problema

Queremos analizar las asociaciones entre filas (individuos) y columnas (categorías), pero no es posible hacerlo bien en el espacio original.


Espacio original  
(alta dimensión)



- Cada punto representa un individuo.
- Las categorías están distribuidas de forma compleja.



Lo que observamos (pero no comprendemos bien)  
Relaciones difíciles de interpretar



- No hay estructura evidente.
- Es difícil detectar grupos, oposiciones o perfiles.

### 1.5 ¿Por qué es un problema importante?

Los datos categóricos están en muchos ámbitos:

- Ciencias sociales: encuestas, estudios de opinión, comportamiento, etc.
- Marketing: preferencias, segmentación, satisfacción, etc.
- Biología: presencia/ausencia de especies, síntomas, etc.
- Educación: rendimiento por niveles, tipo de centro, etc.

Comprender las asociaciones fila–columna es clave para tomar decisiones, segmentar, explicar y comunicar hallazgos.

El ACS busca representar filas (individuos) y columnas (categorías) en un mapa conjunto de baja dimensión de modo que las distancias reflejen sus **asociaciones** (desviaciones respecto a la independencia).

### 1 Partimos de una tabla de contingencia

Contamos cuántas veces aparece cada combinación individuo–categoría.

|                    |               | Categorías (columnas) |                |     |                |            |
|--------------------|---------------|-----------------------|----------------|-----|----------------|------------|
|                    |               | C <sub>1</sub>        | C <sub>2</sub> | ... | C <sub>J</sub> | Total fila |
| Individuos (filas) | 1             | 7                     | 2              | ... | 3              | 12         |
|                    | 2             | 1                     | 6              | ... | 1              | 8          |
|                    | ⋮             | ⋮                     | ⋮              | ⋮   | ⋮              | ⋮          |
|                    | I             | 4                     | 1              | ... | 5              | 10         |
|                    | Total columna | 12                    | 9              | ... | 14             | n          |

Si filas y columnas fueran independientes, esperaríamos frecuencias “equilibradas”.

### 2 Calculamos perfiles

Convertimos cada fila y cada columna en distribuciones (porcentajes).

**Perfil de fila** (cómo se distribuye cada individuo entre categorías)

|   |      |      |     |      |
|---|------|------|-----|------|
| 1 | 0.58 | 0.17 | ... | 0.25 |
| 2 | 0.13 | 0.75 | ... | 0.13 |
| ⋮ |      |      |     |      |

**Perfil de columna** (cómo se distribuyen los individuos en cada categoría)

|                |      |      |     |      |
|----------------|------|------|-----|------|
| C <sub>1</sub> | 0.25 | 0.08 | ... | 0.40 |
| C <sub>2</sub> | 0.58 | 0.25 | ... | 0.07 |
| ⋮              |      |      |     |      |

Estos perfiles describen comportamientos relativos.

### 3 Medimos qué tan distintos son de la independencia

Comparamos cada perfil con el perfil “esperado” si hubiera independencia (distribución promedio).

#### Ejemplo fila 1

|                          |      |      |     |      |
|--------------------------|------|------|-----|------|
| Esperado (independencia) | 0.30 | 0.30 | ... | 0.40 |
|--------------------------|------|------|-----|------|


|                    |      |      |     |      |
|--------------------|------|------|-----|------|
| Observado (fila 1) | 0.58 | 0.17 | ... | 0.25 |
|--------------------|------|------|-----|------|

|                                   |       |       |     |       |
|-----------------------------------|-------|-------|-----|-------|
| Desviación = Observado – Esperado | +0.28 | −0.13 | ... | −0.15 |
|-----------------------------------|-------|-------|-----|-------|

Hacemos lo mismo para todas las filas y columnas.

### 4 Resumimos las desviaciones principales


Buscamos las direcciones (ejes) que explican la mayor parte de estas desviaciones.



Estas direcciones son ortogonales y ordenadas por la información que capturan.

### 5 Proyectamos filas y columnas en esos ejes

Cada fila y cada columna se proyectan sobre las mismas direcciones.




Puntos cercanos = perfiles similares (asociación positiva).  
Puntos opuestos = perfiles opuestos.  
Cerca del origen = comportamiento promedio (independencia).

### ¿Qué significa el mapa final?


#### Proximidad fila–columna

Si una fila (individuo) está cerca de una columna (categoría), ese individuo tiene más probabilidad relativa de esa categoría.




#### Proximidad entre filas

Filas cercanas tienen perfiles de categorías similares.




#### Proximidad entre columnas

Columnas cercanas atraen a los mismos tipos de individuos.




#### Lados opuestos

Puntos en lados opuestos del origen tienden a estar asociados negativamente (perfiles opuestos).



#### Cerca del origen

Puntos cerca del origen tienen perfiles cercanos al promedio (poca información específica).



### En resumen



**Del conteo a perfiles:** transformamos frecuencias en perfiles para eliminar efectos de tamaño.



**Medimos desviaciones:** cuantificamos cuánto se alejan de la independencia.



**Encontramos ejes principales:** resumimos la estructura en pocas direcciones.



**Mapa conjunto:** representamos filas y columnas juntas manteniendo sus asociaciones.

### 1.1 Datos: tabla de contingencia

Tenemos  $I$  filas (individuos) y  $J$  columnas (categorías). La tabla contiene los conteos  $n_{ij}$ .

|               | 1        | 2        | ...      | $J$      | Total fila |
|---------------|----------|----------|----------|----------|------------|
| 1             | $n_{11}$ | $n_{12}$ | ...      | $n_{1J}$ | $r_1$      |
| 2             | $n_{21}$ | $n_{22}$ | ...      | $n_{2J}$ | $r_2$      |
| $\vdots$      | $\vdots$ | $\vdots$ | $\ddots$ | $\vdots$ | $\vdots$   |
| $I$           | $n_{I1}$ | $n_{I2}$ | ...      | $n_{IJ}$ | $r_I$      |
| Total columna | $c_1$    | $c_2$    | ...      | $c_J$    | $n$        |

- $r_i$  = total de la fila  $i$
- $c_j$  = total de la columna  $j$
- $n$  = total general


### 1.1.2 Idea del modelo

El ACS busca representar filas y columnas en un mapa de pocas dimensiones de modo que:

Perfiles (distribuciones) similares queden cerca,  
y perfiles distintos queden lejos.

¿Qué es un perfil?

- Perfil de fila  $i$ : cómo se distribuye el individuo  $i$  entre las categorías.
- Perfil de columna  $j$ : cómo se distribuyen los individuos en la categoría  $j$ .



### 1.3 Métrica y medida de inercia (sencillo)

Medimos las distancias entre perfiles usando la métrica  $\chi^2$  (ji-cuadrado).

Distancia entre dos perfiles de fila ( $i$  y  $k$ ):

$$d^2(i, k) = \sum_{j=1}^J \frac{1}{c_j} (p_{ij} - p_{kj})^2$$

donde  $p_{ij} = \frac{n_{ij}}{r_i}$  es el perfil de fila  $i$ .

La "inercia total" es la variabilidad total respecto a la independencia:

$$I_{total} = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - r_i c_j / n)^2}{r_i c_j / n}$$

Cuanta más inercia explican las dimensiones, mejor representación.

**Objetivo del ACS:** encontrar ejes (direcciones) que expliquen la mayor inercia posible y proyectar filas y columnas sobre ellos.

### 1.4 Paso a paso del algoritmo del ACS (versión sencilla)

#### 1 Preparar datos

- Calcular totales de filas  $r_i$ , totales de columnas  $c_j$  y total  $n$ .
- Calcular proporciones  $P = N/n$ , donde  $P_{ij} = n_{ij}/n$ .
- Calcular perfiles de filas  $p_{ij} = n_{ij}/r_i$  y perfiles de columnas  $p_{cj}^{(col)} = n_{ij}/c_j$ .

#### 2 Construir la matriz de residuos tipificados

Comparamos lo observado con lo esperado bajo independencia ( $r_i c_j / n$ ).

$$S = D_r^{-1/2} (P - r c^T) D_c^{-1/2}$$

donde

- $D_r$ : diagonal con  $r_i/n$
- $D_c$ : diagonal con  $c_j/n$
- $r c^T$ : matriz de independencia

#### 3 Descomponer (SVD)

Aplicamos descomposición en valores singulares:

$$S = U \Sigma V^T$$

- $U$  y  $V$ : vectores (direcciones) de filas y columnas.
- $\Sigma$ : valores singulares (cuánta inercia explica cada dimensión).

#### 4 Elegir dimensión $K$

Elegimos  $K$  dimensiones (normalmente 2 o 3) que expliquen la mayor parte de la inercia.

Inercia explicada hasta  $K$ :

$$\frac{\sum_{k=1}^K \sigma_k^2}{\sum_{k=1}^{\min(I-1, J-1)} \sigma_k^2}$$

(típicamente 60%–90%).

#### 5 Calcular coordenadas

Las coordenadas (puntos) de filas y columnas en las  $K$  dimensiones:

**Filas (individuos):**

$$F_K = D_r^{-1/2} U_K \Sigma_K$$

(matriz  $I \times K$ )

**Columnas (categorías):**

$$G_K = D_c^{-1/2} V_K \Sigma_K$$

(matriz  $J \times K$ )

$U_K, V_K, \Sigma_K$ : primeras  $K$  columnas o valores de  $U, V$  y  $\Sigma$ .


#### 6 Representar e interpretar

Dibujamos filas (puntos azules) y columnas (puntos verdes) en el plano de las dos primeras dimensiones (o más, si se desea).


- Puntos cercanos  $\rightarrow$  perfiles similares (asociación positiva).
- Puntos opuestos  $\rightarrow$  perfiles opuestos (asociación negativa).
- Cerca del origen  $\rightarrow$  comportamiento promedio (independencia).

### 1.5 ¿Qué obtenemos?


Representación conjunta




Proximidad = asociación



Calidad de la representación



### 1.6 Resumen del algoritmo en una línea




**En esencia:** el ACS transforma la tabla en perfiles, mide desviaciones respecto a la independencia, encuentra las direcciones que mejor explican esas desviaciones y proyecta filas y columnas para visualizar las asociaciones.

# GRÁFICOS QUE PUEDEN OBTENERSE EN UN ANÁLISIS DE CORRESPONDENCIA SIMPLE (ACS)


## 1. MAPA FACTORIAL CONJUNTO (BIPLOT)

Filas (individuos) y columnas (categorías) en el mismo plano.




## 2. MAPA DE FILAS

Solo se representan las filas (individuos).




## 3. MAPA DE COLUMNAS

Solo se representan las columnas (categorías).




## 4. SCREE PLOT (INERCIA EXPLICADA)

Porcentaje de inercia explicado por cada dimensión.




## 5. INERCIA ACUMULADA

Inercia acumulada al incluir más dimensiones.




## 6. CONTRIBUCIONES DE FILAS

Qué filas contribuyen más a cada dimensión.




## 7. CONTRIBUCIONES DE COLUMNAS

Qué columnas contribuyen más a cada dimensión.




## 8. COS² (CALIDAD DE REPRESENTACIÓN)

Calidad con la que cada punto está representado en el plano factorial.




## 9. HEATMAP DE RESIDUOS $\chi^2$

Desviaciones respecto a la independencia. Azul: menor de lo esperado. Rojo: mayor de lo esperado.



## 10. PERFILES (DISTRIBUCIONES)

Distribución de cada fila entre las categorías. (Perfiles de fila)




## 11. COORDENADAS FACTORIALES

Coordenadas de filas y columnas en cada dimensión.

|      | Filas (individuos) |       |       | Columnas (categorías) |       |
|------|--------------------|-------|-------|-----------------------|-------|
|      | Dim 1              | Dim 2 |       | Dim 1                 | Dim 2 |
| Ind1 | 1.23               | 0.45  | Cat A | 1.15                  | 0.30  |
| Ind2 | -0.85              | 0.67  | Cat B | -0.90                 | 0.95  |
| Ind3 | -1.10              | -0.32 | Cat C | -1.20                 | -0.40 |
| Ind4 | 0.40               | -1.05 | Cat D | 0.75                  | -0.85 |
| Ind5 | 1.05               | -0.80 | Cat E | 0.20                  | 0.10  |
| Ind6 | -0.73              | -0.15 | ...   | ...                   | ...   |


## 12. MAPA FACTORIAL 3D

Representación conjunta en tres dimensiones.




## 13. CLUSTER SOBRE MAPA FACTORIAL

Agrupamiento (clusters) de filas en el mapa factorial.




## 14. TRAYECTORIAS FACTORIALES

Evolución de puntos (filas o columnas) a lo largo del tiempo.



## 15. GRÁFICO DE MASAS

Tamaño de los puntos proporcional a sus masas (peso).



## 1.1 VENTAJAS DEL ACS



### Representación visual intuitiva

Ofrece un mapa de pocas dimensiones que facilita la comprensión de asociaciones complejas entre categorías e individuos.



### Captura asociaciones (no solo correlaciones)

El ACS se basa en desviaciones respecto a la independencia, por lo que detecta cualquier tipo de asociación.



### Detección de patrones y estructuras

Permite identificar grupos de individuos, categorías similares, oposiciones y perfiles característicos.



### Adecuado para datos categóricos

Diseñado específicamente para tablas de contingencia; no requiere supuestos fuertes sobre las distribuciones.



### Flexibilidad interpretativa

Permite analizar tanto filas como columnas en el mismo espacio o por separado, y estudiar su contribución y calidad.



### Simplicidad computacional

El algoritmo es relativamente sencillo (basado en SVD) y está implementado en la mayoría de paquetes estadísticos.

## 1.2 DESVENTAJAS DEL ACS



### Sensibilidad al tamaño muestral

Con muestras pequeñas, el mapa puede ser inestable y las interpretaciones poco fiables.



### Dependencia de la escala de perfiles

Las distancias se basan en perfiles; categorías muy raras pueden tener un peso exagerado.



### Posible sobre-interpretación

No todo lo que aparece cerca en el mapa es "importante". Debe apoyarse en inercia, contribuciones y  $\cos^2$ .



### Solo asociaciones, no causalidad

El ACS describe patrones relacionales, pero no implica relaciones causales.



### Dificultad con muchas categorías raras

Muchas categorías con frecuencias muy bajas generan ruido y pueden distorsionar la estructura.



### Dependencia del número de dimensiones elegidas

La interpretación puede cambiar según las dimensiones conservadas; elegir  $K$  inadecuado puede ocultar estructura.

## 1.3 ¿QUÉ CONCLUIMOS DEL ACS?

El ACS permite transformar una tabla de contingencia en un mapa factorial que resume las asociaciones entre filas y columnas.

### ¿Qué podemos interpretar?

- Asociaciones positivas: filas y columnas cercanas en el mapa.
- Asociaciones negativas (oposiciones): puntos en lados opuestos.
- Perfiles promedio (independencia): puntos cerca del origen.
- Grupos de individuos con perfiles similares: nubes de filas juntas.
- Categorías con comportamientos similares: nubes de columnas juntas.
- Qué puntos explican la estructura: usando contribuciones e inercia explicada.

### Conclusión clave

El ACS es una herramienta exploratoria y descriptiva poderosa para entender la estructura de datos categóricos, proporcionando una visión global e interpretable de las asociaciones fila-columna.



**Regla práctica:** use siempre el mapa conjunto junto con inercia explicada, contribuciones y  $\cos^2$  para interpretar.

## 1.4 ¿CUÁNDO USAR EL ACS?

- ✓ Cuando tenemos una tabla de contingencia de dos variables categóricas (filas e columnas).
- ✓ Queremos explorar asociaciones sin imponer un modelo previo.
- ✓ Buscamos segmentación de individuos basada en sus perfiles de categorías.
- ✓ Queremos identificar qué categorías caracterizan a cada grupo.
- ✓ Usamos datos de encuestas, marketing, ciencias sociales, biología, educación, etc.

### No es la mejor opción cuando:


- ✗ Existen muchas variables categóricas (usar ACM).
- ✗ Queremos predecir una variable respuesta (usar modelos supervisados).
- ✗ Las frecuencias esperadas son extremadamente bajas en casi todas las celdas (revisar el diseño de datos).

## 1.5 EXTENSIÓN: ANÁLISIS DE CORRESPONDENCIA MÚLTIPLE (ACM)

El ACM generaliza el ACS cuando hay más de dos variables categóricas.

### Idea principal

Transforma un conjunto de variables categóricas en un conjunto de variables binarias (0/1) mediante codificación disyuntiva completa, y luego aplica un ACS a esa tabla indicador.



### Interpretación en el ACM

- Las "columnas" ahora son las modalidades (categorías) de todas las variables.
- El mapa muestra asociaciones entre individuos y modalidades, así como entre modalidades.
- Permite identificar perfiles típicos, grupos de individuos y variables que discriminan grupos.

## 1.6 ACS vs ACM: diferencia clave

|               | ACS                                               | ACM                                                      |
|---------------|---------------------------------------------------|----------------------------------------------------------|
| Tipo de datos | Dos variables categóricas (tabla de contingencia) | Tres o más variables categóricas (conjunto de variables) |
| Entrada       | Tabla $I \times J$                                | Tabla de datos ( $n \times p$ categóricas)               |
| Método        | Perfiles de filas/columnas + SVD                  | Codificación disyuntiva + ACS                            |
| Salida        | Mapa filas y columnas                             | Mapa individuos y modalidades                            |
| Uso típico    | Estudiar asociación entre dos variables           | Explorar estructura de datos categóricos multivariados   |

### Ejemplos de uso del ACM

- Segmentación de clientes (sexo, edad, ingresos, preferencias, zona...).
- Análisis de encuestas con muchas preguntas categóricas.
- Estudios de percepción, satisfacción o comportamiento.
- Análisis exploratorio de grandes bases de datos cualitativas.

### 1.1 ¿Qué datos usa?


Tabla disyuntiva completa  $Z$  (0/1):  
individuos (filas)  $\times$  modalidades (columnas).

| Individuos | Modalidades (variables categóricas) |          |                 |             |          |                 |          |             |          |                 |
|------------|-------------------------------------|----------|-----------------|-------------|----------|-----------------|----------|-------------|----------|-----------------|
|            | $X_1^{(1)}$                         | ...      | $X_{K_1}^{(1)}$ | $X_1^{(2)}$ | ...      | $X_{K_2}^{(2)}$ | ...      | $X_1^{(j)}$ | ...      | $X_{K_j}^{(j)}$ |
| 1          | 1                                   | 0        | ...             | 0           | 1        | ...             | 0        | ...         | 1        | 0               |
| 2          | 0                                   | 1        | ...             | 0           | 0        | ...             | 1        | ...         | 0        | 1               |
| $\vdots$   | $\vdots$                            | $\vdots$ | $\vdots$        | $\vdots$    | $\vdots$ | $\vdots$        | $\vdots$ | $\vdots$    | $\vdots$ | $\vdots$        |
| $n$        | 0                                   | 0        | ...             | 1           | 0        | ...             | 0        | ...         | 1        | 0               |

- Cada fila: un individuo.
- Cada columna: una modalidad de alguna variable.
- 1 si el individuo posee la modalidad, 0 en otro caso.

### 1.2 Idea del ACM

Representa simultáneamente individuos y modalidades en un mapa de pocas dimensiones.



### 1.3 Métrica e inercia

Se usa la **distancia ji-cuadrado** entre perfiles de filas (individuos) y de columnas (modalidades).

$$d^2(i, i') = \sum_{j=1}^p \frac{1}{c_j} (z_{ij} - z_{i'j})^2$$

donde  $c_j = \frac{1}{n} \sum_{i=1}^n z_{ij}$  es el perfil de la modalidad  $j$ .

La **inercia total** (variabilidad total) es:

$$I_{total} = \sum_{j=1}^p \frac{c_j(1 - c_j)}{n}$$

**Objetivo del ACM:** encontrar ejes (dimensiones) que expliquen la mayor inercia posible.

### 1.4 Paso a paso del algoritmo (versión estándar)

#### 1 Preparar datos

Construir la tabla disyuntiva completa  $Z$  ( $n \times p$ ) con 0/1.  
Calcular perfiles de filas  $r_i$  y de columnas  $c_j$ .  
( $r_i$ : suma fila  $i$  /  $n$ ,  
 $c_j$ : suma columna  $j$  /  $n$ )

#### 2 Residuos tipificados

Eliminar el efecto de los márgenes (perfiles).  
$$S = D_r^{-1/2} (Z - rc^T) D_c^{-1/2}$$
  
donde  $D_r$  y  $D_c$  son matrices diagonales con  $r_i$  y  $c_j$ .

#### 3 Descomposición (SVD)

Descomponer  $S$  en valores singulares.  
$$S = U \Sigma V^T$$
  
•  $U$ : vectores singulares de filas  
•  $V$ : vectores singulares de columnas  
•  $\Sigma$ : valores singulares

#### 4 Elegir dimensión $K$

Elegir las  $K$  primeras dimensiones ( $K = 2$  o  $3$ ) que expliquen la mayor parte de la inercia.  
$$\lambda_k = \frac{\sigma_k^2}{\sum_{l=1}^r \sigma_l^2}$$
  
( $r$  = rango de  $S$ )

#### 5 Coordenadas principales

Obtener coordenadas (factores).  
**Individuos:**  
$$F = D_r^{-1/2} U_K \Sigma_K$$
  
**Modalidades:**  
$$G = D_c^{-1/2} V_K \Sigma_K$$
  
con  $U_K, V_K, \Sigma_K$ : primeras  $K$ .

### 1.5 ¿Qué obtenemos?


#### Mapa conjunto

Individuos y modalidades en el mismo mapa.



#### Perfiles similares

Puntos cercanos = asociación positiva.



#### Perfiles opuestos

Puntos opuestos = asociación negativa.



### 1.6 Resumen en una línea



★ El ACM generaliza el **Análisis de Correspondencia Simple** para más de dos variables categóricas, permitiendo analizar patrones complejos de asociación entre individuos y modalidades en un único mapa de pocas dimensiones.

# **ANÁLISIS DE CORRESPONDENCIA SINPLE & MULTIPLE**

Rachit Vargas (MBA | Engineer)

[rachit.vargas@ulead.ac.cr](mailto:rachit.vargas@ulead.ac.cr)

(+506) 8474-3543