

T-SNE & UMAP


Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543

1. Métodos de reducción de la dimensionalidad

- El método de reducción de dimensionalidad busca simplificar conjuntos de datos complejos (con muchas variables o columnas) transformándolos en una versión más manejable, conservando la mayor información posible de los datos originales.




1.1 PCA (1901) vs t-SNE (2008) y UMAP (2018)


- El ACP es un algoritmo de reducción de dimensión lineal (genera combinaciones lineales de las variables originales).
- Muchas veces la información de un conjunto de variables no se puede extraer como una combinación lineal de estas variables. En tales situaciones, hay una serie de algoritmos de reducción de dimensiones no lineales a los que podemos recurrir tales como t-SNE y UMAP.
- t-distributed Stochastic Neighbor Embedding (t-SNE), and Uniform Manifold Approximation and Projection (UMAP).

DATOS: ESTUDIANTES


Método: ACP



Método: t-SNE




Método: UMAP




DATOS: IRIS


Método: ACP



Método: t-SNE




Método: UMAP




DATOS: DÍGITOS ESCRITOS A MANO


Método: ACP



Método: t-SNE



Método: UMAP




2. t-SNE (t-distributed Stochastic Neighbor Embedding)

- t-SNE es un método de reducción de la dimensión que se basa en el método “Stochastic Neighbor Embedding” desarrollado originalmente por Sam Roweis y Geoffrey Hinton, así Laurens van der Maaten propuso una variante usando la distribución t de Student.
- t-SNE mide la distancia entre todas las observaciones (individuos) en el conjunto de datos (i.e. calcula la matriz de distancias), y luego aleatoriza las observaciones en (generalmente) dos nuevos ejes.


$$d(x, y) = \sqrt{\sum_{i=1}^n (y_i - x_i)^2}$$

2. t-SNE (t-distributed Stochastic Neighbor Embedding)

- Para cada punto x_i , t-SNE calcula la distancia de otro x_j punto, para luego scalar la misma y cuantificar la probabilidad de ser sea su vecino.




2. t-SNE (t-distributed Stochastic Neighbor Embedding)



2. t-SNE (t-distributed Stochastic Neighbor Embedding)

- El segundo paso en el algoritmo t-SNE es aleatorizar los individuos a lo largo de, generalmente dos nuevos ejes, de aquí es de donde proviene “Stochastic” como parte del nombre del método.
- t-SNE calcula las distancias entre los individuos en este nuevo espacio aleatorio de baja dimensión y las convierte en probabilidades como antes. La única diferencia es que en lugar de usar la distribución normal, ahora usa la distribución t de Student, como se muestra en la siguiente Figura:



2. t-SNE (t-distributed Stochastic Neighbor Embedding)

3. Mapa inicial en baja dimensión

Se colocan los puntos en $\mathbb{R}^d$ ($d = 2$ o 3) aleatoriamente.


$$\mathbf{y}_i \sim \mathcal{N}(0, e^2 \mathbf{I}_d).$$



4. Probabilidades en baja dimensión (con t-Student)

Se calculan las distancias $\|\mathbf{y}_i - \mathbf{y}_j\|$ en el mapa y se convierten en probabilidades usando la distribución t-Student con $\nu = 1$ grado de libertad:


$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq \ell} (1 + \|\mathbf{y}_k - \mathbf{y}_\ell\|^2)^{-1}}, \quad q_{ii} = 0.$$



Las colas pesadas permiten que puntos moderadamente lejanos se separen más.

6. Resultado final

El algoritmo converge cuando los cambios en KL son pequeños. El mapa final preserva la estructura local: puntos cercanos permanecen cerca y los clústeres se hacen visibles.




2. t-SNE (t-distributed Stochastic Neighbor Embedding)

10.4.5 Paso 5: Comparar y ajustar (proceso iterativo)

El objetivo de *t*-SNE es que el mapa en baja dimensión (Q) reproduzca lo mejor posible las relaciones de *similitud* del espacio original (P). Para lograrlo, el algoritmo repite el siguiente ciclo hasta que las probabilidades P y Q sean muy parecidas (es decir, hasta que la divergencia KL sea pequeña).

1 Comparar


Medimos qué tan diferentes son las probabilidades P (original) y Q (mapa 2D) usando la divergencia KL.



KL grande → mapa malo
KL pequeña → mapa bueno

2 Ajustar posiciones


Movemos los puntos en el mapa 2D para disminuir la diferencia entre P y Q .




- Acercamos puntos que en P son similares (tenían alta probabilidad).
- Alejamos puntos que en P son diferentes (tenían baja probabilidad).

3 Repetir

Volvemos a calcular Q , comparamos con P y ajustamos otra vez.



2. t-SNE (t-distributed Stochastic Neighbor Embedding)



2. t-SNE (t-distributed Stochastic Neighbor Embedding)

- ¿Por qué la distribución t student y no Gaussian?
 - En espacios de muchas dimensiones, muchos puntos pueden estar “moderadamente lejos”.
 - Cuando se intenta meter todo en 2D, una distribución normal hace que esos puntos lejanos tengan probabilidades extremadamente pequeñas.
 - Entonces el algoritmo termina empujando demasiados puntos hacia el centro, es decir, todo se amontona.

2. t-SNE (t-distributed Stochastic Neighbor Embedding)

- ¿Qué hace la t-Student?
 - La distribución t-Student tiene colas más pesadas que la normal. Eso significa que: los puntos lejanos siguen teniendo una probabilidad relativamente importante.
 - Por lo tanto el algoritmo puede separarlos mejor en el mapa 2D.


2. t-SNE (t-distributed Stochastic Neighbor Embedding)

Figura 1.2. Explicación del método t-SNE. *t*-SNE (*t*-distributed Stochastic Neighbor Embedding) es un método no lineal de reducción de dimensionalidad que busca representar datos de alta dimensión en 2D o 3D preservando las relaciones locales entre los puntos.

1. Relaciones en alta dimensión

Para cada punto x_i , se calcula la probabilidad condicional de que x_j sea su vecino usando una distribución gaussiana:

$$p_{j|i} = \frac{\exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|x_i - x_k\|^2}{2\sigma_i^2}\right)}$$




La probabilidad $p_{j|i}$ es alta si x_j está cerca de x_i en el espacio original.

2. Representación en baja dimensión

En el espacio reducido (2D o 3D), las similitudes entre puntos y_i y y_j se modelan con una distribución t de Student (con 1 g.l.):

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$




La distribución t de Student permite que puntos moderadamente lejanos ejerzan fuerzas repulsivas más fuertes.

3. Optimización (ajuste del mapa)

t -SNE encuentra las posiciones $\{y_i\}$ que minimizan la divergencia KL entre las distribuciones P y Q :

$$KL(P||Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$



El mapa final preserva las relaciones locales: puntos cercanos en alta dimensión permanecen cercanos en baja dimensión.

3. UMAP (Uniform Manifold Aproximation and Projection)

- UMAP es un algoritmo de reducción de dimensión no lineal que cuyo objetivo es mejorar algunas de las limitaciones de t-SNE.
- Funciona de manera similar a t-SNE (encuentra distancias en un espacio con muchas variables y luego intenta reproducir estas distancias en un espacio de baja dimensión), pero difiere, entre otras cosas, en la forma en la que mide dichas distancias.
- UMAP es considerablemente más rápido que t-SNE.


3. UMAP (Uniform Manifold Aproximation and Projection)

- UMAP es un algoritmo determinístico. Es decir, dada la misma entrada, siempre dará la misma salida.
- Esto significa que, a diferencia de t-SNE, se pueden proyectar nuevos individuos en la representación de menor dimensión. O sea, que UMAP puede ser usado como Método Supervisado.
- UMAP preserva tanto la estructura local como la global de los datos. Esto permite interpretar individuos y clústeres cercanos en bajas dimensiones como similares también en dimensiones altas.

3. UMAP (Uniform Manifold Approximation and Projection)


1 Datos en muchas dimensiones

Cada punto es un dato con muchas características (dimensiones).




2 Buscar vecinos cercanos

Para cada punto, UMAP busca sus vecinos cercanos y mide qué tan fuerte es su relación (similitud).




3 Construir el grafo global

Se repite para todos los puntos, obteniendo un grafo que representa la estructura del conjunto de datos.



4 Proyección inicial en 2D


Se coloca cada punto en un plano 2D de forma aleatoria.



5 Optimización: acercar y alejar


UMAP mueve los puntos para:

- **Acercar** los vecinos que estaban cerca
- **Alejar** los que estaban lejos




6 Resultado intermedio

Después de muchas iteraciones, la estructura empieza a tomar forma: clusters y relaciones mejor representados.



7 Proyección 2D final

UMAP entrega la representación final en 2D que preserva la estructura del grafo original lo mejor posible.




3. UMAP (Uniform Manifold Aproximation and Projection)

Paso 2

- El **paso 2** es realmente el corazón de UMAP. ¿Qué tan conectado está cada punto con sus vecinos? (No usa solo distancia “bruta”, sino una noción de **probabilidad de cercanía**)
- Supongamos un punto x_i :
 - busca sus k vecinos más cercanos
 - mide qué tan cerca están
 - convierte esas distancias en probabilidades de conexión

$$p_{ij} = \exp \left(- \frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i} \right)$$

ρ_i = radio de cercanía
 σ_i = controla la escala total



3. UMAP (Uniform Manifold Aproximation and Projection)


Paso 3

- En el paso anterior, UMAP ya encontró vecinos cercanos y convirtió distancias en probabilidades de conexión
- Probabilidades altas $\rightarrow$ puntos similares | Probabilidades bajas $\rightarrow$ puntos menos relacionados
- Luego de conocer las relaciones entre puntos, UMAP toma las vecindades locales y forma una gran red global de relaciones (grafos) conectando cada punto por el método “fuzzy union”


$$p_{ij}^{(sym)} = p_{ij} + p_{ji} - p_{ij}p_{ji}$$

- Suponga $A_{\rho_{ij}} = 0.9$ y $B_{\rho_{ij}} = 0.5$ entonces $0.9 + 0.5 - (0.9)(0.5) = 0.95$

3. UMAP (Uniform Manifold Approximation and Projection)



3. UMAP (Uniform Manifold Approximation and Projection)




4. COLOCACIÓN DE PUNTOS EN 2D (OPTIMIZACIÓN)

Objetivo: encontrar posiciones en 2D para que q_{ij} se parezca a p_{ij}


Matriz de probabilidades del grafo global (paso 3)

	1	2	3	4	5	6	7	8	9	10
1	0	0.99	0.97	0.64	0.58	0	0	0	0	0
2	0.99	0	0.96	0	0	0	0	0	0	0
3	0.97	0.96	0	0.66	0.51	0	0	0	0	0
4	0.64	0	0.66	0	0.91	0	0	0	0	0
5	0.58	0	0.51	0.91	0	0	0	0	0	0
6	0	0	0	0	0	0	0.99	0.80	0.75	0.64
7	0	0	0	0	0	0.99	0	0.94	0.12	0
8	0	0	0	0	0	0.80	0.74	0	0.98	0.64
9	0	0	0	0	0	0.75	0.12	0.58	0	0.65
10	0	0	0	0	0	0.64	0	0.64	0.62	0


Inicialización aleatoria




Iteración 1




Iteración 10



Iteración 50




Iteración 200+ (convergencia)



5. FORMACIÓN DEL GRAFO EN 2D

Iteración 1




Matriz de distancias en 2D

	1	2	3	4	5	6	7	8	9	10
1	0	1.25	1.32	1.18	1.21	2.71	2.63	2.80	2.68	2.75
2	1.25	0	1.14	1.22	1.19	2.58	2.49	2.67	2.55	2.62
3	1.32	1.14	0	1.08	1.15	2.65	2.56	2.73	2.61	2.68
4	1.18	1.22	1.08	0	1.05	2.50	2.42	2.59	2.47	2.55
5	1.21	1.19	1.15	1.05	0	2.55	2.46	2.63	2.51	2.58
6	2.71	2.58	2.65	2.50	2.55	0	0.82	0.76	0.91	0.88
7	2.63	2.49	2.56	2.42	2.46	0.82	0	0.74	0.83	0.80
8	2.80	2.67	2.73	2.59	2.63	0.76	0.74	0	0.78	0.73
9	2.68	2.55	2.61	2.47	2.51	0.91	0.83	0.78	0	0.77
10	2.75	2.62	2.68	2.55	2.58	0.88	0.80	0.73	0.77	0

Matriz de probabilidades q_{ij} en 2D

	1	2	3	4	5	6	7	8	9	10
1	0	0.10	0.82	1.12	1.21	0.00	0.00	0.00	0.00	0.00
2	1.15	0	0.14	0.10	1.11	0.00	0.00	0.00	0.00	0.00
3	0.08	0.12	0	0.14	1.12	0.00	0.00	0.00	0.00	0.00
4	0.12	0.10	0.14	0	0.16	0.00	0.00	0.00	0.00	0.00
5	0.11	0.11	0.12	0.16	0	0.00	0.00	0.00	0.00	0.00
6	0.00	0.00	0.00	0.00	0.00	0	0.33	0.37	0.27	0.29
7	0.00	0.00	0.00	0.00	0.00	0.33	0	0.39	0.31	0.34
8	0.00	0.00	0.00	0.00	0.00	0.37	0.39	0	0.36	0.40
9	0.00	0.00	0.00	0.00	0.00	0.27	0.31	0.36	0	0.35
10	0.00	0.00	0.00	0.00	0.00	0.29	0.34	0.40	0.35	0

Iteración 10




Matriz de distancias en 2D

	1	2	3	4	5	6	7	8	9	10
1	0	0.52	0.61	0.45	0.55	2.20	2.15	2.28	2.18	2.25
2	0.52	0	0.56	0.48	0.44	2.10	2.05	2.18	2.08	2.15
3	0.61	0.56	0	0.50	0.52	2.18	2.12	2.26	2.15	2.22
4	0.45	0.48	0.50	0	0.43	2.05	2.00	2.12	2.02	2.08
5	0.55	0.44	0.52	0.43	0	2.12	2.06	2.18	2.09	2.16
6	2.20	2.10	2.18	2.05	2.12	0	0.68	0.71	0.66	0.70
7	2.15	2.05	2.12	2.00	2.06	0.68	0	0.67	0.63	0.66
8	2.28	2.18	2.26	2.12	2.18	0.71	0.67	0	0.69	0.64
9	2.18	2.08	2.15	2.02	2.09	0.66	0.63	0.69	0	0.67
10	2.25	2.15	2.22	2.08	2.16	0.70	0.66	0.64	0.67	0

Matriz de probabilidades q_{ij} en 2D

	1	2	3	4	5	6	7	8	9	10
1	0	0.35	0.28	0.42	0.32	0.00	0.00	0.00	0.00	0.00
2	0.55	0	0.31	0.37	0.42	0.00	0.00	0.00	0.00	0.00
3	0.28	0.31	0	0.33	0.30	0.00	0.00	0.00	0.00	0.00
4	0.40	0.37	0.33	0	0.44	0.00	0.00	0.00	0.00	0.00
5	0.32	0.42	0.30	0.44	0	0.00	0.00	0.00	0.00	0.00
6	0.00	0.00	0.00	0.00	0.00	0	0.45	0.41	0.41	0.48
7	0.00	0.00	0.00	0.00	0.00	0.45	0	0.46	0.50	0.47
8	0.00	0.00	0.00	0.00	0.00	0.41	0.46	0	0.44	0.48
9	0.00	0.00	0.00	0.00	0.00	0.48	0.50	0.44	0	0.46
10	0.00	0.00	0.00	0.00	0.00	0.43	0.47	0.48	0.46	0

Iteración 50




Matriz de distancias en 2D

	1	2	3	4	5	6	7	8	9	10
1	0	0.22	0.27	0.19	0.23	2.10	2.05	2.13	2.08	2.18
2	0.52	0	0.21	0.18	0.20	2.02	1.95	2.06	2.01	2.01
3	0.27	0.21	0	0.20	0.22	2.08	2.03	2.11	2.06	2.09
4	0.19	0.18	0.20	0	0.17	1.98	1.94	2.02	1.97	2.01
5	0.23	0.20	0.22	0.17	0	2.04	1.99	2.07	2.02	2.05
6	2.10	2.02	2.08	1.98	2.04	0	0.36	0.33	0.35	0.34
7	2.05	1.98	2.03	1.94	1.99	0.36	0	0.32	0.34	0.31
8	2.13	2.06	2.11	2.02	2.07	0.33	0.32	0	0.33	0.31
9	2.08	2.01	2.06	1.97	2.02	0.35	0.34	0.33	0	0.32
10	2.12	2.05	2.09	2.01	2.05	0.34	0.31	0.31	0.32	0

Matriz de probabilidades q_{ij} en 2D

	1	2	3	4	5	6	7	8	9	10
1	0	0.72	0.62	0.73	0.52	0.00	0.00	0.00	0.00	0.00
2	0.70	0	0.72	0.76	0.71	0.00	0.00	0.00	0.00	0.00
3	0.62	0.72	0	0.71	0.66	0.00	0.00	0.00	0.00	0.00
4	0.73	0.76	0.71	0	0.77	0.00	0.00	0.00	0.00	0.00
5	0.52	0.71	0.66	0.77	0	0.00	0.00	0.00	0.00	0.00
6	0.00	0.00	0.00	0.00	0.00	0	0.80	0.84	0.81	0.83
7	0.00	0.00	0.00	0.00	0.00	0.80	0	0.86	0.82	0.88
8	0.00	0.00	0.00	0.00	0.00	0.84	0.86	0	0.85	0.89
9	0.00	0.00	0.00	0.00	0.00	0.81	0.82	0.85	0	0.87
10	0.00	0.00	0.00	0.00	0.00	0.83	0.88	0.89	0.85	0

Iteración 200+ (final)



Matriz de distancias en 2D

	1	2	3	4	5	6	7	8	9	10
1	0	0.11	0.14	0.10	0.12	2.50	2.45	2.55	2.52	2.48
2	0.11	0	0.10	0.09	0.11	2.42	2.38	2.48	2.45	2.41
3	0.14	0.10	0	0.11	0.13	2.48	2.43	2.53	2.49	2.46
4	0.10	0.09	0.11	0	0.10	2.40	2.35	2.46	2.42	2.39
5	0.12	0.11	0.13	0.10	0	2.44	2.40	2.50	2.46	2.42
6	2.50	2.42	2.48	2.40	2.44	0	0.20	0.18	0.19	0.17
7	2.45	2.38	2.43	2.35	2.40	0.20	0	0.17	0.18	0.16
8	2.55	2.48	2.53	2.46	2.50	0.18	0.17	0	0.16	0.15
9	2.52	2.45	2.49	2.42	2.46	0.19	0.18	0.16	0	0.15
10	2.48	2.41	2.46	2.39	2.42	0.17	0.16	0.15	0.15	0

Matriz de probabilidades q_{ij} en 2D

	1	2	3	4	5	6	7	8	9	10
1	0	0.95	0.92	0.96	0.94	0.00	0.00	0.00	0.00	0.00
2	0.95	0	0.96	0.97	0.95	0.00	0.00	0.00	0.00	0.00
3	0.92	0.96	0	0.94	0.93	0.00	0.00	0.00	0.00	0.00
4	0.96	0.97	0.94	0	0.96	0.00	0.00	0.00	0.00	0.00
5	0.94	0.95	0.93	0.96	0	0.00	0.00	0.00	0.00	0.00
6	0.00	0.00	0.00	0.00	0.00	0	0.97	0.98	0.97	0.98
7	0.00	0.00	0.00	0.00	0.00	0.97	0	0.98	0.97	0.98
8	0.00	0.00	0.00	0.00	0.00	0.98	0.98	0	0.98	0.98
9	0.00	0.00	0.00	0.00	0.00	0.97	0.97	0.98	0	0.98
10	0.00	0.00	0.00	0.00	0.00	0.98	0.98	0.98	0.98	0

¿Por qué cambian las matrices en cada iteración?

Porque al mover los puntos en 2D cambian las distancias d_{ij} entre todos los pares de puntos, y como q_{ij} depende de esas distancias, la matriz de probabilidades también cambia.

¿Qué busca UMAP?

Encontrar posiciones en 2D donde q_{ij} sea lo más parecido posible a p_{ij}

3. UMAP (Uniform Manifold Approximation and Projection)

- UMAP es una técnica de reducción de dimensionalidad que transforma datos complejos en representaciones 2D o 3D preservando principalmente las relaciones de vecindad entre los puntos. Para lograrlo, construye un grafo probabilístico de conexiones locales y luego optimiza iterativamente la posición de los puntos en baja dimensión hasta reproducir lo mejor posible la estructura original de los datos.
- En comparación con t-SNE, UMAP suele ser más rápido, escalable y estable, además de conservar mejor parte de la estructura global entre clusters. Mientras t-SNE se enfoca casi exclusivamente en relaciones locales y puede separar artificialmente los grupos, UMAP mantiene relaciones más coherentes entre clusters y permite interpretar mejor la geometría general del dataset.

T-SNE & UMAP

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543