

INTRODUCCIÓN AL CLUSTERING

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543

1. Introducción al clustering

1.1. Clustering (o agrupamiento) es una técnica de aprendizaje no supervisado que busca identificar grupos naturales de observaciones dentro de un conjunto de datos, de manera que los elementos pertenecientes a un mismo grupo sean más similares entre sí que con los elementos de otros grupos.

1.2. El clustering es una técnica exploratoria que ayuda a comprender la organización interna de un conjunto de datos antes de formular hipótesis o construir modelos predictivos.

1.3. El clustering permite resumir grandes cantidades de datos mediante un número reducido de grupos representativos (centroides).

1.4. El clustering depende de cómo definimos la similitud entre observaciones. Diferentes medidas de similitud pueden producir agrupaciones distintas sobre los mismos datos.

1. Introducción al clustering

¿Por qué es importante en clustering?

Muchos algoritmos utilizan la distancia para determinar qué observaciones son similares.

Distancias pequeñas → observaciones parecidas.

Distancias grandes → observaciones diferentes.

Por ejemplo, en K-Means, cada observación se asigna al centroide más cercano utilizando normalmente distancia euclidiana.

PUNTOS IMPORTANTES ANTES DE LA CLUSTERIZACIÓN

2. Clustering

- No todos los problemas son clusterizables
- Por ende, ¿realmente existen grupos en mis datos o estoy intentando encontrar clústeres donde no los hay?
- El Índice de Hopkins permite medir la **tendencia al agrupamiento (cluster tendency)** de los datos antes de aplicar algoritmos como K-Means o Clustering Jerárquico.
- **Escenario 1: Datos con clústeres reales**
Los puntos forman grupos claramente diferenciados.
- **Escenario 2: Datos aleatorios**
Los puntos están dispersos sin ningún patrón.
- **Escenario 3: Datos uniformemente distribuidos**
No existen agrupaciones naturales.

2. Clustering

Problema de las escalas

- Supongamos dos variables:
- Edad: valores entre 18 y 80.
- Ingresos: valores entre 10 000 y 2 000 000.
- **La variable ingresos dominará la distancia.**
- Por ello, antes de aplicar muchos algoritmos de clustering suele ser necesario:
 - Estandarizar.
 - Normalizar.
 - Escalar los datos.

2. Clustering

Sensibilidad a valores atípicos

- La distancia euclidiana utiliza diferencias al cuadrado.
- **Esto provoca que observaciones extremadamente alejadas tengan un impacto muy grande.**
- Consecuencia:
 - Los outliers pueden distorsionar los resultados del clustering.
 - Los centroides pueden desplazarse hacia regiones poco representativas.

2. Clustering



Alta dimensionalidad

- A medida que aumenta el número de variables:
 - Las distancias tienden a parecerse entre sí.
 - Resulta más difícil distinguir observaciones cercanas de lejanas.
- Este fenómeno se conoce como la **maldición de la dimensionalidad**.

Problemas comunes en clustering

1. Problema de escalas



Variables con diferentes escalas hacen que una domine la distancia.



Idea clave: escalar las variables para que ninguna domine la distancia.

2. Sensibilidad a valores atípicos



Los outliers pueden distorsionar los centroides y afectar la formación de clústeres.



Idea clave: detectar y tratar outliers para evitar distorsiones en los clústeres.

3. Alta dimensionalidad

En muchas dimensiones, las distancias se vuelven menos informativas.



Efecto:

- Es difícil distinguir qué puntos están realmente cerca o lejos.
- Los algoritmos basados en distancia pierden efectividad.

Idea clave: reducir dimensionalidad o usar métricas/algoritmos más adecuados.



Resumen: escalar variables, tratar outliers y considerar la dimensionalidad son pasos clave para lograr clústeres significativos y confiables.

MATRIZ DE DISTANCIA

1. Conjunto de datos (5 variables)

Sea $X = \{x_1, x_2, x_3, x_4, x_5\} \subset \mathbb{R}^5$ el conjunto de 5 observaciones con 5 variables $(v_1, v_2, v_3, v_4, v_5)$.

Observación	v_1	v_2	v_3	v_4	v_5
x_1	2	1	0	4	3
x_2	3	4	1	0	2
x_3	0	2	3	1	4
x_4	5	0	2	3	1
x_5	1	3	4	2	0

3. Matriz de distancias euclidianas

Sea $D = (d_{ij}) \in \mathbb{R}^{5 \times 5}$ la matriz de distancias, donde $d_{ij} = d(x_i, x_j)$.

	x_1	x_2	x_3	x_4	x_5
x_1	0	5.292	4.243	5.831	4.359
x_2	5.292	0	4.243	5.099	3.606
x_3	4.243	4.243	0	5.196	3.162
x_4	5.831	5.099	5.196	0	5.385
x_5	4.359	3.606	3.162	5.385	0

4. Propiedades de la matriz de distancias euclidianas

- $d_{ij} \geq 0 \quad \forall i, j$
- $d_{ii} = 0 \quad \forall i$
- $d_{ij} = d_{ji} \quad \forall i, j$ (simetría)
- $d_{ij} \leq d_{ik} + d_{kj} \quad \forall i, j, k$ (desigualdad triangular)

2. Distancia euclidiana

La distancia euclidiana entre dos observaciones $x_i, x_j \in \mathbb{R}^5$ se define como

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^5 (x_{ik} - x_{jk})^2}.$$

Ejemplo: distancia entre x_1 y x_2

$$\begin{aligned} d(x_1, x_2) &= \sqrt{(2-3)^2 + (1-4)^2 + (0-1)^2 + (4-0)^2 + (3-2)^2} \\ &= \sqrt{1+9+1+16+1} = \sqrt{28} \approx 5.292. \end{aligned}$$

En forma matricial:

$$D = \begin{bmatrix} 0 & 5.292 & 4.243 & 5.831 & 4.359 \\ 5.292 & 0 & 4.243 & 5.099 & 3.606 \\ 4.243 & 4.243 & 0 & 5.196 & 3.162 \\ 5.831 & 5.099 & 5.196 & 0 & 5.385 \\ 4.359 & 3.606 & 3.162 & 5.385 & 0 \end{bmatrix}.$$

Nota: Esta matriz es la base para métodos de agrupamiento jerárquico, MDS (escalamiento multidimensional), k -medoids, DBSCAN, entre otros.

3. Matriz de distancia

MATRIZ DE DISTANCIAS (Distancia Euclidiana)

Objeto	A	B	C	D
A	0.00	5.00	6.08	8.60
B	5.00	0.00	4.24	4.12
C	6.08	4.24	0.00	4.12
D	8.60	4.12	4.12	0.00

Fórmula de la distancia euclidiana

$$d(i,j) = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$$

Coordenadas de los puntos


- A (1, 1)
- B (4, 5)
- C (7, 2)
- D (8, 6)

Ejemplo de cálculo

Distancia entre A y B:

$$\begin{aligned} d(A,B) &= \sqrt{(4 - 1)^2 + (5 - 1)^2} \\ &= \sqrt{3^2 + 4^2} \\ &= \sqrt{25} = 5.00 \end{aligned}$$

REPRESENTACIÓN DE LOS PUNTOS
Y DISTANCIAS EUCLIDIANAS



DISTANCIAS

4.1 Euclidean

4.1. La distancia euclidiana es la medida de distancia más común entre dos puntos en un espacio geométrico.

4.2. Representa la longitud de la línea recta que conecta dos observaciones.


En dos dimensiones:

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

En n dimensiones:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

4.1 Euclidean



4.2 Manhattan

La **distancia de Manhattan** (también llamada **distancia L1** o **city-block distance**) mide la distancia entre dos puntos sumando las diferencias absolutas en cada dimensión.

Su nombre proviene de la ciudad de Manhattan, donde para desplazarse normalmente se recorren calles horizontales y verticales, en lugar de moverse en línea recta.

Fórmula

Para dos observaciones $A = (x_1, x_2, \dots, x_n)$ y $B = (y_1, y_2, \dots, y_n)$:

$$d(A, B) = \sum_{i=1}^n |x_i - y_i|$$

Supongamos dos puntos en un plano:

$$A = (2, 3)$$


$$B = (7, 8)$$

La distancia Manhattan es:

$$|7 - 2| + |8 - 3| \\ 5 + 5 = 10$$

4.2 Manhattan


Mientras que la distancia euclidiana mide la línea recta entre ambos puntos, la distancia Manhattan mide cuánto tendríamos que recorrer si solo pudiéramos movernos horizontal y verticalmente.



Recorrido total:

$$5 + 5 = 10$$

4.2 Manhattan



— **Distancia de Manhattan (L^1)**

Se mueve solo horizontal y verticalmente.

— **Distancia Euclidiana (L^2)**

Línea recta entre los puntos.

$$L^1 = |x_2 - x_1| + |y_2 - y_1|$$

(Suma de diferencias absolutas)


$$L^2 = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

(Raíz de la suma de cuadrados)

Intuición: La distancia **Manhattan (L^1)** mide cuánto recorreríamos si solo pudiéramos movernos por calles (horizontal y vertical).

La distancia **Euclidiana (L^2)** mide el “atajo” en línea recta.

4.2 Manhattan



4.3 Chebyshev

- La distancia de Chebyshev mide la separación entre dos puntos considerando únicamente la mayor diferencia absoluta entre sus variables.
- También se conoce como **Distancia del máximo**

Fórmula

$$d(x, y) = \max_i |x_i - y_i|$$

- La distancia es simplemente la diferencia más grande observada entre todas las dimensiones.

4.3 Chebyshev

$$d(x, y) = \max_i |x_i - y_i|$$

Variable	A	B
Edad	25	30
Ingreso	40	55
Deuda	10	18

Variable	Diferencia
Edad	5
Ingreso	15
Deuda	8


La distancia Chebyshev es:

$$\max(5, 15, 8) = 15$$


Solo importa la diferencia más grande.

4.3 Chebyshev


Euclidean Distance



Manhattan Distance




Chebyshev Distance



$$\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \quad |x_1 - x_2| + |y_1 - y_2| \quad \max(|x_1 - x_2|, |y_1 - y_2|)$$

4.4 Otras distancias





EVALUACIÓN DE CLUSTERING

Hopkins Statistic

- Esta técnica permite medir la tendencia natural de los datos a formar grupos antes de aplicar cualquier algoritmo de clustering.
- La idea principal del método es comparar la distribución de los datos reales con una distribución completamente aleatoria. Si los datos presentan agrupamientos naturales, entonces los puntos reales estarán más cercanos entre sí que los puntos generados aleatoriamente.
- El estadístico de Hopkins toma valores entre 0 y 1:

Valor de H	Interpretación
≈ 0.5	Datos distribuidos aleatoriamente, no clusterizables
> 0.7	Evidencia de estructura de clusters
cercano a 1	Fuerte tendencia a formar clusters
cercano a 0	Distribución uniforme o regular

Hopkins Statistic



VAT (Visual Assessment of Tendency)

El VAT (Visual Assessment of Tendency) es una técnica visual diseñada específicamente para responder una pregunta fundamental en clustering:


Lo que hace es:

- calcular las distancias entre todos los puntos,
- reorganizar esas distancias,
- y construir una imagen tipo mapa de calor (*heatmap*).

Si los datos tienen clusters naturales, aparecen bloques oscuros cuadrados sobre la diagonal principal.


VAT (Visual Assessment of Tendency)

$$R = \begin{pmatrix} 0 & 0.73 & 0.19 & 0.71 & 0.16 \\ 0.73 & 0 & 0.59 & 0.12 & 0.78 \\ 0.19 & 0.59 & 0 & 0.55 & 0.19 \\ 0.71 & 0.12 & 0.55 & 0 & 0.74 \\ 0.16 & 0.78 & 0.19 & 0.74 & 0 \end{pmatrix}$$




VAT

$$\tilde{R} = \left(\begin{array}{cc|ccc} 0 & 0.12 & 0.59 & 0.73 & 0.78 \\ 0.12 & 0 & 0.55 & 0.71 & 0.74 \\ \hline 0.59 & 0.55 & 0 & 0.19 & 0.19 \\ 0.73 & 0.71 & 0.19 & 0 & 0.16 \\ 0.78 & 0.74 & 0.19 & 0.16 & 0 \end{array} \right)$$




VAT (Visual Assessment of Tendency)



VAT (Visual Assessment of Tendency)


Random data



value



4. Otros objetos visuales



INTRODUCCIÓN AL CLUSTERING

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543