

EVALUACIÓN DE ALGORITMOS DE CLUSTERING

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543

1. Introducción

- Antes de aplicar un algoritmo de clustering, es fundamental preguntarse si los datos realmente poseen una estructura agrupable.
- No todos los conjuntos de datos contienen grupos naturales; en muchos casos los datos pueden estar **distribuidos de manera aleatoria, uniforme** o sin separaciones claras.
- Si se ignora este análisis previo, los algoritmos de clustering producirán clusters artificiales aunque en realidad no existan patrones significativos.
- Por esta razón, **evaluar la *clusterabilidad*** de un problema es una etapa importante dentro del análisis exploratorio de datos.
- Este proceso permite determinar si tiene sentido aplicar técnicas de agrupamiento y evita interpretaciones erróneas o conclusiones engañosas.

1. Introducción

Realizar pruebas de clusterabilidad también tiene ventajas prácticas:


- Reduce el riesgo de construir modelos inútiles.
- Evita desperdiciar recursos computacionales.
- Permite validar que los patrones encontrados son reales y no producto del azar.
- Mejora la interpretación y confiabilidad de los resultados.
- En consecuencia, antes de ejecutar algoritmos como K-Means, DBSCAN o clustering jerárquico, **es recomendable aplicar técnicas que evalúen si los datos presentan evidencia de agrupamiento.**
- Métodos como el estadístico de **Hopkins**, **VAT**, **Gap Statistic** o **análisis visual mediante PCA y UMAP** ayudan a responder una pregunta clave: ¿Los datos contienen grupos naturales o cualquier cluster obtenido sería artificial?

2. Hopkins Statistic


- Esta técnica permite medir la tendencia natural de los datos a formar grupos antes de aplicar cualquier algoritmo de clustering.
- La idea principal del método es comparar la distribución de los datos reales con una distribución completamente aleatoria. Si los datos presentan agrupamientos naturales, entonces los puntos reales estarán más cercanos entre sí que los puntos generados aleatoriamente.
- El estadístico de Hopkins toma valores entre 0 y 1:

Valor de H	Interpretación
≈ 0.5	Datos distribuidos aleatoriamente, no clusterizables
> 0.7	Evidencia de estructura de clusters
cercano a 1	Fuerte tendencia a formar clusters
cercano a 0	Distribución uniforme o regular

2. Hopkins Statistic



DATOS ALEATORIOS (sin estructura)



3. Silhouette Score

Silhouette Score es una de las métricas más populares. Mide:

- qué tan cerca está un punto de su propio cluster,
- y qué tan lejos está de otros clusters.

La fórmula es:



$$s = \frac{b - a}{\max(a, b)}$$

donde:

- a : distancia promedio al mismo cluster,
- b : distancia promedio al cluster vecino más cercano.


3. Silhouette Score

Silhouette analysis for KMeans clustering on sample data with $n_clusters = 6$




3. Silhouette Score

The silhouette plot for the various clusters.



The visualization of the clustered data.



4. VAT (Visual Assessment of Tendency)

El VAT (Visual Assessment of Tendency) es una técnica visual diseñada específicamente para responder una pregunta fundamental en clustering:


Lo que hace es:

- calcular las distancias entre todos los puntos,
- reorganizar esas distancias,
- y construir una imagen tipo mapa de calor (*heatmap*).

Si los datos tienen clusters naturales, aparecen bloques oscuros cuadrados sobre la diagonal principal.

4. VAT (Visual Assessment of Tendency)

$$R = \begin{pmatrix} 0 & 0.73 & 0.19 & 0.71 & 0.16 \\ 0.73 & 0 & 0.59 & 0.12 & 0.78 \\ 0.19 & 0.59 & 0 & 0.55 & 0.19 \\ 0.71 & 0.12 & 0.55 & 0 & 0.74 \\ 0.16 & 0.78 & 0.19 & 0.74 & 0 \end{pmatrix}$$




$= I$




VAT

$$\tilde{R} = \left(\begin{array}{cc|ccc} 0 & 0.12 & 0.59 & 0.73 & 0.78 \\ 0.12 & 0 & 0.55 & 0.71 & 0.74 \\ \hline 0.59 & 0.55 & 0 & 0.19 & 0.19 \\ 0.73 & 0.71 & 0.19 & 0 & 0.16 \\ 0.78 & 0.74 & 0.19 & 0.16 & 0 \end{array} \right)$$




$= \tilde{I}$

4. VAT (Visual Assessment of Tendency)



4. VAT (Visual Assessment of Tendency)


Random data




value



4. Otros objetos visuales



4. Otros objetos visuales



5. Calibración modelos de clustering

- La calibración en clustering permite ajustar parámetros como número de clusters, métricas de distancia y densidad para obtener grupos compactos, separados e interpretables.
- Sin una buena calibración, los algoritmos pueden generar clusters artificiales o mezclar patrones distintos, produciendo resultados engañosos.
- Además, calibrar mejora la estabilidad y confiabilidad del modelo, ayudando a detectar estructuras reales en los datos.
- Esto es fundamental en aplicaciones como segmentación de clientes, medicina o detección de fraude, donde decisiones incorrectas pueden tener alto impacto.

5. Calibración modelos de clustering

```
# 1. Importar librerías
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

# 2. Datos (X ya debe estar escalado)
X = [...] # matriz de datos

# 3. Funciones de distancia a probar y otros parámetros
distancias = ['euclidean', 'manhattan', 'cosine']
k = [3, 4, 5]
inits = ['k-means++', 'random']
max_iter = 300
random_state = 42

# 4. Búsqueda simple de la mejor configuración según Silhouette Score
mejor_score = -1
mejor_config = None
for d in distancias:
    for k_val in k:
        for init in inits:
            modelo = KMeans(n_clusters=k_val, init=init, max_iter=max_iter,
                            n_init=10, random_state=random_state, algorithm='lloyd')
            labels = modelo.fit_predict(X)
            score = silhouette_score(X, labels, metric=d)
            if score > mejor_score:
                mejor_score = score
                mejor_config = {'metric': d, 'k': k_val, 'init': init}

# 5. Resultado
print("Mejor configuración:", mejor_config, "con Silhouette Score:", mejor_score)
```


EVALUACIÓN DE ALGORITMOS DE CLUSTERING

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543