

LEAD University

Examen de Aprendizaje No Supervisado

Ciencia de Datos – Minería de Datos I

Duración estimada: 2 horas

Modalidad: Teórico-práctica

Temas: PCA, ACM, t-SNE, UMAP y Clustering

Parte I. Preguntas de respuesta corta

Responda de forma clara y concisa. No se requiere desarrollar código en esta sección.

1. Explique cuál es el objetivo principal del **Análisis de Componentes Principales (PCA)** y mencione una situación en la que su aplicación podría ser útil dentro de un proyecto de Ciencia de Datos.
2. ¿Qué representa la **varianza explicada** de un componente principal? Explique cómo utilizaría la varianza explicada acumulada para decidir cuántos componentes conservar.
3. ¿Por qué es recomendable **estandarizar las variables** antes de aplicar PCA cuando estas se encuentran medidas en diferentes escalas?
4. Explique qué representa un **componente principal** y por qué los componentes obtenidos mediante PCA no corresponden directamente a las variables originales del conjunto de datos.
5. ¿Cuál es el objetivo del **Análisis de Correspondencias Múltiples (ACM)** y qué tipo de variables son apropiadas para utilizar esta técnica?
6. Explique una diferencia fundamental entre **PCA y ACM** considerando el tipo de información que analiza cada técnica.

7. Explique cómo funciona conceptualmente el algoritmo **K-Means** e indique qué representa el centroide de un cluster.
8. ¿Cuál es el propósito del **método del codo (Elbow Method)** en clustering? Explique qué información se analiza para seleccionar un posible número de clusters.
9. ¿Qué mide el **Silhouette Score** y cómo interpretaría valores cercanos a 1, cercanos a 0 y negativos?
10. Compare brevemente **K-Means** y **DBSCAN**. Indique al menos una situación en la que DBSCAN podría ser más apropiado que K-Means.
11. Explique qué es **t-SNE** y cuál es su principal propósito dentro del aprendizaje no supervisado. ¿En qué se diferencia de PCA cuando se utiliza para representar datos de alta dimensionalidad en dos dimensiones?
12. Explique conceptualmente qué es **UMAP** y mencione una diferencia importante entre UMAP y PCA en términos de la estructura de los datos que intentan preservar.
13. Explique cómo funciona el **clustering jerárquico aglomerativo**. ¿Qué representa un dendrograma y cómo puede utilizarse para decidir una posible cantidad de clusters?
14. En clustering jerárquico se pueden utilizar diferentes criterios de enlace (*linkage*), como **single, complete, average y Ward**. Explique qué determina un criterio de enlace y por qué la selección del método puede modificar los clusters obtenidos.
15. Suponga que se aplican varios algoritmos de clustering sobre un conjunto de datos para el cual **no existen etiquetas reales**. Explique cómo determinaría cuál de las soluciones obtenidas presenta una mejor estructura de clustering. Mencione al menos dos criterios o métricas que podría utilizar y explique brevemente qué información aportan.

Parte II. Desarrollo y aplicación

En esta sección deberá desarrollar dos análisis utilizando Python.

Para cada caso deberá presentar el código utilizado, resultados, visualizaciones e interpretación. Las decisiones tomadas durante el análisis deberán estar justificadas.

Caso 1. Segmentación de vinos mediante reducción de dimensionalidad y clustering

Utilice el conjunto de datos **Wine Quality** para desarrollar un análisis de aprendizaje no supervisado.

El objetivo consiste en determinar si las características fisicoquímicas de los vinos permiten identificar **estructuras o grupos naturales de observaciones**.

Desarrolle las siguientes etapas:

- a) Cargue el conjunto de datos y realice una exploración inicial de su estructura. Identifique las variables disponibles, tipos de datos, valores faltantes y posibles problemas de calidad.
- b) Seleccione las variables numéricas que considere apropiadas para desarrollar el análisis no supervisado. Justifique cualquier variable que decida excluir.
- c) Prepare los datos para el modelado. Analice si es necesario aplicar estandarización y justifique su decisión.
- d) Aplique **PCA** sobre las variables seleccionadas.
- e) Analice la **varianza explicada individual y acumulada** de los componentes principales.
- f) Determine una cantidad razonable de componentes principales que permita reducir la dimensionalidad conservando una proporción adecuada de la información original. Justifique su elección.
- g) Utilizando los componentes seleccionados, implemente un algoritmo de **clustering**. Puede utilizar K-Means, clustering jerárquico, DBSCAN u otro algoritmo visto durante el curso.

- h) Si el algoritmo requiere definir el número de clusters, utilice al menos **dos criterios** para justificar su selección. Por ejemplo:
- Método del codo.
 - Silhouette Score.
 - Análisis del dendrograma.
 - Otro criterio técnicamente justificado.
- i) Visualice los clusters utilizando una representación basada en los primeros componentes principales.
- j) Interprete los clusters encontrados utilizando las **variables originales**. Identifique las principales características que diferencian a cada grupo.
- k) Presente una conclusión sobre los resultados obtenidos. Discuta si la estructura encontrada parece representar una segmentación útil de los vinos.

Importante: La variable `quality`, si se encuentra disponible, no debe utilizarse automáticamente como variable de entrada. El estudiante deberá decidir y justificar su uso o exclusión según el objetivo del análisis.

Caso 2. Descubrimiento de estructuras en Iris Dataset

Utilice el conjunto de datos **Iris** disponible en `scikit-learn`.

Para efectos del modelado, trabaje inicialmente únicamente con las variables predictoras:

- Sepal Length
- Sepal Width
- Petal Length
- Petal Width

La variable correspondiente a la especie (target) **no deberá utilizarse para construir los clusters**. Podrá utilizarse únicamente al final del ejercicio para analizar los resultados obtenidos.

Desarrolle las siguientes etapas:

- a) Cargue el dataset Iris y realice una exploración inicial de las variables.
- b) Analice las escalas y distribuciones de las variables. Determine si es necesario realizar algún proceso de transformación o estandarización.
- c) Aplique una técnica de **reducción de dimensionalidad**. Puede utilizar PCA u otra técnica de reducción estudiada durante el curso. Justifique su selección.
- d) Determine cuántas dimensiones conservará para el análisis posterior y explique el criterio utilizado.
- e) Sobre la representación de menor dimensionalidad, implemente un algoritmo de **clustering** de su elección.
- f) Determine y justifique los parámetros relevantes del algoritmo seleccionado. Si utiliza K-Means, por ejemplo, deberá analizar diferentes valores de k .
- g) Evalúe la calidad de la estructura obtenida utilizando al menos una métrica interna de clustering, como el **Silhouette Score**.

- h) Construya una visualización bidimensional de los clusters utilizando las dimensiones obtenidas mediante la técnica de reducción seleccionada.
- i) Una vez finalizado el clustering, compare los grupos encontrados con las especies reales contenidas en **target**. Para ello puede utilizar una tabla de contingencia, matriz cruzada u otra representación apropiada.
- j) Analice si existe correspondencia entre los clusters descubiertos por el algoritmo y las especies reales de Iris.
- k) Explique por qué **no sería correcto utilizar la variable de especie para entrenar el algoritmo de clustering** en este ejercicio.
- l) Presente una conclusión técnica sobre la capacidad del aprendizaje no supervisado para descubrir la estructura presente en Iris.

Formato de entrega

Para los ejercicios de desarrollo, el estudiante deberá entregar un Notebook de Python (.ipynb) que contenga:

- Código ejecutable y ordenado.
- Explicaciones breves de las decisiones realizadas.
- Visualizaciones correctamente identificadas.
- Resultados de las métricas utilizadas.
- Interpretación de los resultados.
- Conclusiones de cada caso.

El Notebook deberá poder ejecutarse de forma secuencial sin errores.