

EDA y Test Estadísticos

Lead University

Abril, 2026

Objetivo

El estudiante deberá demostrar competencias en la exploración visual de datos (EDA), la validación de supuestos estadísticos y la implementación de modelos de regresión lineal y logística utilizando Python.

1. Dataset 1: Comportamiento y Perfiles de Personalidad

Archivo: `personality_synthetic_dataset.csv`

1.1. Fase 1: Minería Visual (EDA)

Genere los siguientes gráficos e interprételes en términos de negocio/psicología:

- **Distribuciones Cruzadas:** Cree un Pairplot de las variables `social_energy`, `talkativeness` y `deep_reflection` segmentado por `personality_type`. ¿Se observan grupos claramente separables?
- **Análisis de Outliers:** Diseñe un gráfico de violín (*violin plot*) para `risk_taking` según el tipo de personalidad.
- **Estructura de Correlación:** Compute la matriz de correlación y visualícela con un mapa de calor. Identifique variables con correlación superior a 0.7.

1.2. Fase 2: Contraste de Hipótesis e Inferencia

1. **Prueba t de Student:** Evalúe si existe una diferencia significativa en la media de `decision_speed` entre introvertidos y extrovertidos.
 - Realice una prueba de normalidad (Shapiro-Wilk) previa.
 - Si los datos no son normales, aplique la prueba U de Mann-Whitney.
2. **MANOVA:** Ejecute un Análisis Multivariado de Varianza para determinar si el `personality_type` afecta el conjunto de variables: `[empathy, listening_skill, friendliness]`.

1.3. Fase 3: Clasificación (Regresión Logística)

Prediga si un individuo tiene un perfil de Liderazgo Alto (definido como `leadership > 7,5`).

- Utilice como predictores: `public_speaking_comfort`, `stress_handling` y `organization`.
- Interprete los coeficientes: ¿Cuál es el impacto de manejar el estrés en la probabilidad de ser líder?

2. Dataset 2: Análisis Nutricional y Densidad Calórica

Archivo: `Food_Nutrition_Dataset.csv`

2.1. Fase 1: Minería y Perfilamiento

- **Composición por Categoría:** Genere un gráfico de barras apiladas que muestre el promedio de macronutrientes (`protein`, `carbs`, `fat`) para las 10 categorías de alimentos con más registros.
- **Relación Calórica:** Cree un *scatter plot* entre `fat` y `calories`. Agregue una línea de regresión local (LOWESS) para observar la tendencia.

2.2. Fase 2: ANOVA y Comparaciones Múltiples

1. **ANOVA de una vía:** Determine si el contenido de `sugar` varía significativamente entre las categorías: 'fruit' y 'Grain'
2. **Post-Hoc:** Grafique la distribución del `sugar` de acuerdo a las categorías antes mencionadas.

2.3. Fase 3: Regresión Lineal Múltiple

Modele el contenido de `calories` basándose en la composición química.

$$\text{Calories} = \beta_0 + \beta_1(\text{protein}) + \beta_2(\text{carbs}) + \beta_3(\text{fat}) + \beta_4(\text{sugar}) + \epsilon \quad (1)$$

- Interprete los coeficientes.
- Explique el significado de R^2 ajustado en este contexto.