

Asignación: Reducción de Dimensionalidad

Análisis de Componentes Principales (PCA) Multidominio

1. Introducción

El Análisis de Componentes Principales (PCA) es una herramienta de transformación lineal que permite simplificar la estructura de datos multivariados. En esta asignación, aplicaremos PCA sobre tres dominios distintos para identificar patrones ocultos, reducir redundancias y visualizar la dispersión de los datos en espacios de baja dimensión.

2. Descripción de los Conjuntos de Datos

El estudiante deberá trabajar con los archivos proporcionados, realizando una limpieza previa (manejo de nulos y codificación de variables relevantes):

1. **USA Cars Dataset:** Análisis de mercado automotriz. Incluye variables como *price*, *year* y *mileage*. El objetivo es entender qué factores definen el valor y la antigüedad en el plano principal.
2. **Country Data (Help International):** Indicadores de desarrollo como *child_mort*, *exports*, *health*, *income*, *inflation* y *gdpp*. Se busca segmentar países para ayuda humanitaria.
3. **Telco Customer Churn:** Datos de comportamiento de clientes. Incluye *tenure*, *MonthlyCharges* y *TotalCharges*. El reto es observar si el PCA logra separar a los clientes que abandonan (*Churn*) de los que no.

3. Requerimientos de la Tarea

Para cada dataset, se deben generar e interpretar los siguientes productos:

3.1. Visualizaciones Obligatorias

- **Scree Plot:** Mostrar el porcentaje de varianza explicada por cada componente. Justificar cuántos componentes son necesarios para capturar al menos el 80 % de la información.
- **Círculo de Correlación:** Graficar las variables originales como vectores. Analizar la magnitud y dirección de cada variable.
- **Plano Principal (PC1 vs PC2):** Visualizar las observaciones. En *Cars* y *Churn*, usar colores para distinguir categorías (ej. marcas de autos o estado de abandono).
- **Biplot:** Superponer variables y observaciones para explicar la posición de los datos en función de sus atributos.

4. Guía de Interpretación Técnica

El reporte debe responder con rigor a los siguientes puntos de análisis:

Relación de Variables: En el dataset de **Cars**, ¿existe una correlación inversa clara entre *year* y *mileage* en el círculo de correlación? ¿Cómo afecta esto al precio?

Contraste Socioeconómico: En **Country Data**, identifique qué variables se oponen diametralmente (ej. *child_mort* vs *gdpp*). ¿Qué países se ubican en el extremo de la mortalidad infantil según el biplot?

Análisis de Clientes: En **Telco Churn**, determine si las variables de cargos (*MonthlyCharges*) y permanencia (*tenure*) definen ejes ortogonales o si presentan colinealidad.