

Tarea Práctica: Aprendizaje No Supervisado

Segmentación mediante K-Means y Clustering Jerárquico

Curso de Minería de Datos / Aprendizaje Automático

7 de julio de 2026

1. Objetivo de la Actividad

El objetivo de esta tarea es aplicar los algoritmos de agrupamiento (*clustering*) más utilizados en el aprendizaje no supervisado: **K-Means** y **Clustering Jerárquico Aglomerativo**. Los estudiantes desarrollarán habilidades para la preparación de datos, la selección óptima del número de clusters y la interpretación de los resultados en contextos reales.

2. Instrucciones del Trabajo

La tarea se realizará de manera individual o en parejas (según las indicaciones del profesor) y consistirá en el desarrollo de los siguientes puntos:

1. **Selección de Datos:** Deberán seleccionar **dos (2)** bases de datos distintas de la plataforma [Kaggle](#).

- **Dataset 1:** Orientado a un problema de negocio o comportamiento de clientes (ej. *Customer Segmentation, Mall Customers, Credit Card Dataset*).
- **Dataset 2:** Orientado a un ámbito científico, biológico o de características técnicas (ej. *Iris dataset, Wine classification, Penguin dataset*).

Nota: Los datasets elegidos deben contener variables numéricas que justifiquen el análisis de distancia.

2. **Preprocesamiento de Datos:** Para ambos conjuntos de datos, realicen una limpieza básica (manejo de valores nulos o atípicos) y es **obligatorio** normalizar o estandarizar las variables numéricas antes de aplicar los algoritmos, asegurando que las escalas no sesguen las distancias.
3. **Determinación del Número Óptimo de Clusters (K):** Antes de ejecutar K-Means, se debe determinar el número adecuado de agrupaciones. Para ello, implementen y grafiquen el **Método del Codo de Jambu** (*Elbow Method*), evaluando la Inercia o la Suma de Cuadrados Intra-cluster (WCSS) para un rango de K (por ejemplo, de 1 a 10).
4. **Aplicación de Algoritmos:** Para cada uno de los dos datasets, ejecuten:
 - **K-Means:** Utilizando el número K óptimo identificado en el paso anterior.
 - **Clustering Jerárquico:** Utilizando un método de vinculación adecuado (*Ward, Complete, o Average Linkage*) y visualizando el **Dendrograma** correspondiente para validar el corte del número de clusters.

5. **Análisis y Conclusiones Visuales:** Generen gráficos de dispersión (añadiendo componentes principales PCA si el dataset tiene más de dos dimensiones) donde se visualicen los clusters asignados por cada algoritmo.